

机器学习理论研究导引

作业二

庄镇华 502022370071

2023 年 4 月 15 日

作业提交注意事项

- (1) 本次作业提交截止时间为 **2023/04/26 23:59:59**, 截止时间后不再接收作业, 本次作业记零分;
- (2) 作业提交方式: 使用此 LaTeX 模板书写解答, 只需提交编译生成的 pdf 文件, 将 pdf 文件提交至南大网盘:
<https://box.nju.edu.cn/u/d/efa16754c94d4904b95d/>
- (3) pdf 文件命名方式: 学号-姓名-作业号-v 版本号, 例 MG1900000-张三-1-v1; 如果需要更改已提交的解答, 请在截止时间之前提交新版本的解答, 并将版本号加一;
- (5) 未按照要求提交作业, 或 **pdf 命名方式不正确**, 将会被扣除部分作业分数.

1 [25pts] Growth Function and Sauer's Lemma

Sauer 引理提供了增长函数的上界, 本题旨在探讨该上界是否是紧的.

- (1) [10pts] 令 $\mathcal{H} = \{h_{a,b} \mid a \leq b, h_{a,b}(x) = \mathbb{I}(x \in [a, b])\}$ 为 \mathbb{R} 上所有区间函数构成的函数空间. 计算 \mathcal{H} 的增长函数 $\Pi_{\mathcal{H}}(m)$.
- (2) [15pts] 对于任意 VC 维 d , Sauer 引理是否是紧的? 即是否存在 VC 维为 d 的函数空间 \mathcal{H} , 使得 $\Pi_{\mathcal{H}}(m) = \sum_{i=0}^d \binom{m}{i}$?

Solution.

- (1) 将 x_1, x_2, \dots, x_m 进行大小排序, 仅有 1 个样本输出为 1 的情况有 m 种, 仅有 2 个样本输出为 1 的情况有 $m-1$ 种, \dots , 所有样本输出为 1 的情况有 1 种, 所有样本输出为 0 的情况有 1 种, 则

$$\begin{aligned} \Pi_{\mathcal{H}}(m) &= \max_{|D|=m} |\mathcal{H}|_D = \max_{\{x_1, \dots, x_m\} \subset \mathcal{X}} |\{(h(x_1), \dots, h(x_m)) \mid h \in \mathcal{H}\}| \\ &= 1 + m + m - 1 + \dots + 1 \\ &= \frac{m^2 + m + 2}{2} \end{aligned}$$

- (2) 首先计算区间函数的 VC 维, 其中 $h_{a,b}(x) = \mathbb{I}(x \in [a, b])$. 令 $D = \{1, 2\}$, 易知 \mathcal{H} 能打散 D , 因此 $VC(\mathcal{H}) \geq 2$. 对于任意大小为 3 的样本集 $D' = \{x_1, x_2, x_3\}$, 不妨设 $x_1 < x_2 < x_3$, 则分类结果 $(1, 0, 1)$ 不能被 \mathcal{H} 中的任何区间函数实现, 因为当 $h_{a,b}(x_1) = 1$ 且 $h_{a,b}(x_3) = 1$ 时, 必有 $h_{a,b}(x_2) = 1$. 所以 \mathcal{H} 无法打散任何大小为 3 的样本集, 于是根据 VC 维的定义可知区间函数的 VC 维为 2,

根据 Sauer 引理有, $\Pi_{\mathcal{H}}(m) \leq \binom{m}{0} + \binom{m}{1} + \binom{m}{2} = 1 + m + \frac{m(m-1)}{2} = \frac{m^2 + m + 2}{2}$, 而根据第 (1) 问, $\Pi_{\mathcal{H}}(m) = \frac{m^2 + m + 2}{2}$, 因此存在 VC 维为 2 的区间函数空间 \mathcal{H} , 使得 $\Pi_{\mathcal{H}}(m) = \sum_{i=0}^d \binom{m}{i}$, 也即对于任意 VC 维 d , Sauer 引理是紧的.

2 [20pts] Rademacher Complexity Property

固定正整数 $m \geq 1$, 对任意实数 $\alpha \in \mathbb{R}$ 以及由 $\mathcal{X} \rightarrow \mathbb{R}$ 的映射组成的任意两个假设集 \mathcal{H}_1 、 \mathcal{H}_2 , 试证明下列关于 Rademacher 复杂度的等式/不等式成立.

- (1) [5pts] 若 \mathcal{H}_1 中仅包含一个假设, 即 $\mathcal{H}_1 = \{h_1\}$, 则 $\mathfrak{R}_m(\mathcal{H}_1) = 0$.
- (2) [5pts] $\mathfrak{R}_m(\alpha\mathcal{H}_1) = |\alpha|\mathfrak{R}_m(\mathcal{H}_1)$.
- (3) [5pts] $\mathfrak{R}_m(\mathcal{H}_1 + \mathcal{H}_2) = \mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2)$.
- (4) [5pts] $\mathfrak{R}_m(\mathcal{H}) \leq \mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2)$, 其中假设集 \mathcal{H} 定义为 $\mathcal{H} = \{\max(h_1, h_2) : h_1 \in \mathcal{H}_1, h_2 \in \mathcal{H}_2\}$.

提示: 最后一问中你可能会用到等式 $\max(a, b) = \frac{1}{2}(a + b + |a - b|)$ 以及 Talagrand's Lemma (又称为 Contraction Lemma). 关于 Talagrand's Lemma, 可参见《Understanding Machine Learning: From Theory to Algorithms》 Lemma 26.9 (书第 26 章, pp. 381-382)

Solution.

- (1) $\mathfrak{R}_m(\mathcal{H}_1) = \mathbb{E}_{X \subset \mathcal{X}: |X|=m} [\mathbb{E}_{\sigma} [\sup_{h \in \mathcal{H}_1} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i)]]$, 又因为 σ_i 是 $\{-1, 1\}$ 上服从均匀分布的随机变量, $\mathcal{H}_1 = \{h_1\}$, 所以 $\mathfrak{R}_m(\mathcal{H}_1) = \mathbb{E}_{X \subset \mathcal{X}: |X|=m} [\mathbb{E}_{\sigma} [\frac{1}{m} \sum_{i=1}^m \sigma_i h_1(\mathbf{x}_i)]] = \mathbb{E}_{X \subset \mathcal{X}: |X|=m} [\frac{1}{m} \sum_{i=1}^m \mathbb{E}_{\sigma} [\sigma_i] h_1(\mathbf{x}_i)] = 0$
- (2) $\mathfrak{R}_m(\alpha\mathcal{H}_1) = \mathbb{E}_{X \subset \mathcal{X}: |X|=m} [\mathbb{E}_{\sigma} [\sup_{h \in \mathcal{H}_1} \frac{1}{m} \sum_{i=1}^m \alpha \sigma_i h(\mathbf{x}_i)]]$
 $= \mathbb{E}_{X \subset \mathcal{X}: |X|=m} |\alpha| [\mathbb{E}_{\sigma} [\sup_{h \in \mathcal{H}_1} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i)]]$
 $= |\alpha| \mathbb{E}_{X \subset \mathcal{X}: |X|=m} [\mathbb{E}_{\sigma} [\sup_{h \in \mathcal{H}_1} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i)]]$
 $= |\alpha| \mathfrak{R}_m(\mathcal{H}_1)$
- (3) $\mathfrak{R}_m(\mathcal{H}_1 + \mathcal{H}_2) = \mathbb{E}_{X \subset \mathcal{X}: |X|=m} [\mathbb{E}_{\sigma} [\sup_{h_1 \in \mathcal{H}_1, h_2 \in \mathcal{H}_2} \frac{1}{m} \sum_{i=1}^m \sigma_i (h_1(\mathbf{x}_i) + h_2(\mathbf{x}_i))]]$
 $= \mathbb{E}_{X \subset \mathcal{X}: |X|=m} [\mathbb{E}_{\sigma} [\sup_{h \in \mathcal{H}_1} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i)]] + \mathbb{E}_{X \subset \mathcal{X}: |X|=m} [\mathbb{E}_{\sigma} [\sup_{h \in \mathcal{H}_2} \frac{1}{m} \sum_{i=1}^m \sigma_i h(\mathbf{x}_i)]]$
 $= \mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2)$
- (4) $\mathfrak{R}_m(\mathcal{H}) = \mathfrak{R}_m(\max(\mathcal{H}_1, \mathcal{H}_2)) = \mathfrak{R}_m(\frac{\mathcal{H}_1 + \mathcal{H}_2 + |\mathcal{H}_1 - \mathcal{H}_2|}{2}) = \frac{\mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2) + \mathfrak{R}_m(|\mathcal{H}_1 - \mathcal{H}_2|)}{2}$

由 Talagrand's Lemma, 即设 f 为 L -Lipschitz 连续函数, 并且 \mathcal{H} 是假设集, 那么 $\mathfrak{R}_m(f \circ \mathcal{H}) \leq L \cdot \mathfrak{R}_m(\mathcal{H})$;

易知函数 $f(x) = |x|$ 为 1-Lipschitz 连续函数, 因此 $\mathfrak{R}_m(|\mathcal{H}_1 - \mathcal{H}_2|) \leq 1 \cdot \mathfrak{R}_m(\mathcal{H}_1 - \mathcal{H}_2) = \mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(-\mathcal{H}_2) = \mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2)$;

因此 $\mathfrak{R}_m(\mathcal{H}) = \frac{\mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2) + \mathfrak{R}_m(|\mathcal{H}_1 - \mathcal{H}_2|)}{2} \leq \frac{\mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2) + \mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2)}{2} = \mathfrak{R}_m(\mathcal{H}_1) + \mathfrak{R}_m(\mathcal{H}_2)$.

3 [25pts] VC Dimension and PAC Learnability

证明: 若概念类 \mathcal{C} 的 VC 维是无穷, 则 \mathcal{C} 不是 PAC 可学的.

Proof.

首先直接给出 **No-Free-Lunch 定理**. 设 A 为针对域 \mathcal{X} 上损失为 0、1 的二分类任务的任意算法, $m < |\mathcal{X}|/2$ 为训练集样本大小, 那么存在 $\mathcal{X} \times \{0, 1\}$ 上的分布 \mathcal{D} 使得 1) 存在函数 $f: \mathcal{X} \rightarrow \{0, 1\}$ 使得 $L_{\mathcal{D}}(f) = 0$; 2) 存在样本集 $S \sim \mathcal{D}^m$, 使得至少有 $1/7$ 的概率 $L_{\mathcal{D}}(A(S)) \geq 1/8$ 成立。

然后利用**反证法**证明原命题。若概念类 \mathcal{C} 是 PAC 可学的, 那么存在算法 A 使得对于任意 $\epsilon, \delta > 0$, 存在 $M(\epsilon, \delta)$ 对于任意分布 \mathcal{D} 满足: 如果 $m > M(\epsilon, \delta)$, 有 $P_{S \sim \mathcal{D}^m}(L_{\mathcal{D}}(A(S)) > L_{\mathcal{D}}(h^*) + \epsilon) < \delta$, 其中 $h^* = \arg \min_{h \in \mathcal{H}} L_{\mathcal{D}}(h)$ 。

令 $\epsilon < 1/8, \delta < 1/7, m > M(\epsilon, \delta)$, 因为 $VC(\mathcal{H}) = \infty$, 所以 \mathcal{H} 可以打散 $x_1, \dots, x_{2m} \in \mathcal{X}$, 根据 **No-Free-Lunch 定理**, 存在 x_1, \dots, x_{2m} 及其标签上的分布 \mathcal{D} 满足: 存在 $f: \mathcal{X} \rightarrow \{0, 1\}$ 使得 $L_{\mathcal{D}}(f) = 0, P_{S \sim \mathcal{D}^m}(L_{\mathcal{D}}(A(S)) > 1/8) < 1/7$ 成立。

因为 \mathcal{D} 为 $\{x_1, \dots, x_{2m}\}$ 及其标签上的分布, 并且 \mathcal{H} 可以打散这个样本集, 因此 $L_{\mathcal{D}}(h^*) = 0$, $P_{S \sim \mathcal{D}^m}(L_{\mathcal{D}}(A(S)) > L_{\mathcal{D}}(h^*) + \epsilon) \geq P_{S \sim \mathcal{D}^m}(L_{\mathcal{D}}(A(S)) > 1/8) > 1/7 > \delta$, 这与 $P_{S \sim \mathcal{D}^m}(L_{\mathcal{D}}(A(S)) > L_{\mathcal{D}}(h^*) + \epsilon) < \delta$ 矛盾, 因此假设不成立, 原命题得证。

4 [30pts] VC Dimension and the Number of Parameters

回顾课件中精确计算 VC 维的几个例子:

- 阈值函数的假设空间为 $\mathcal{H} = \{\text{sign}(\mathbb{I}(x \leq a) - 0.5) : a \in \mathbb{R}\}$, 假设有 1 个参数, 且 \mathcal{H} 的 VC 维为 1;
- 区间函数的假设空间为 $\mathcal{H} = \{\text{sign}(\mathbb{I}(x \in [a, b]) - 0.5) : a, b \in \mathbb{R}, a \leq b\}$, 假设有 2 个参数, 且 \mathcal{H} 的 VC 维为 2;
- 课件中给出了 \mathbb{R}^d 中线性超平面的假设空间, 假设有 $d + 1$ 个参数, 且假设空间的 VC 维为 $d + 1$.

在这些例子中, 假设的参数个数等于假设空间的 VC 维. 该结论是否对任意假设空间都成立呢? 试给出下列各小问的假设空间的数学表达式, 假设的参数个数, VC 维, 并给出 VC 维的证明.

(1) [10pts] 所有经过 $(0, 0)$ 点的正弦函数, 函数值大于等于 0 时标记为 +1, 否则为 -1.

(2) [20pts] 所有正三角形, 三角形边缘与内部为 +1, 外部为 -1.

提示: 正三角形的 VC 维可能较难证明, 可以尝试给出尽可能紧的上界与下界.

Proof.

假设的参数个数不一定等于假设空间的 VC 维. 4(1) 中参数个数为 1 但是假设空间的 VC 维为无穷。

(1) 假设空间的数学表达式为 $\mathcal{H} = \{\text{sign}(\sin(\alpha x)) : \alpha \in \mathbb{R}\}$, 假设的参数个数为 1, VC 维为 ∞ , 事实上, 对于任意大小 m , 选择样本点 $x_i = 10^{-i}$, 其中 $i = 1, \dots, m$, 对于任意给定的标签 y_1, y_2, \dots, y_m , 其中 $y_i \in \{-1, 1\}$, 只需要设定 $\alpha = \pi(1 + \sum_{i=1}^m \frac{(1 - y_i)10^i}{2})$ 即可满足条件, 由 m 的任意性可知该假设空间的 VC 维为无穷。

(2) 假设空间的数学表达式为 $\mathcal{H} = \{h_{(a_1, b_1), (a_2, b_2)}\}$, 此处点 $(a_1, b_1), (a_2, b_2)$ 不重合, 且为正三角形的两个顶点, 约定其第三个顶点位于右下方。

$$h_{(a_1, b_1), (a_2, b_2)}(x_1, x_2) = \begin{cases} +1 & \text{如果 } (x_1, x_2) \text{ 位于定义的正三角形边缘与内部} \\ -1 & \text{其余情况} \end{cases}$$

假设的参数个数为 4, VC 维为 6 或 7。

易知任意三角形的 VC 维为 7, 因此正三角形的 VC 维一定小于等于 7, 又容易得出存在 6 个点 (取正六边形的 6 个顶点) 可以被正三角形空间打散, 因此正三角形的 VC 维大于等于 6, 因此正三角形的 VC 维是 6 或 7。

下面首先证明任意三角形的 VC 维为 7。圆上七等分点所有可能的标签都可以使用三角形打散, 因为在所有情况中, 负标签最多形成 3 个连续块, 而三角形的一条边可以隔出一个块。但是, 任意 8 个点都没办法被打散, 如果存在一个点在其余点的凸包内, 则无法将该点标记为负例, 将其他点标记为正例; 否则, 无法以交替的 +, -, +, -, +, -, +, - 顺序标记这些点。