

机器学习理论研究导引

作业四

庄镇华 502022370071

2023 年 5 月 31 日

作业提交注意事项

- (1) 本次作业提交截止时间为 **2023/06/03 23:59:59**, 截止时间后不再接收作业, 本次作业记零分;
- (2) 作业提交方式: 使用此 LaTeX 模板书写解答, 只需提交编译生成的 pdf 文件, 将 pdf 文件提交至南大网盘:
<https://box.nju.edu.cn/u/d/5a7e3aed5389469aaa57/>
- (3) pdf 文件命名方式: 学号-姓名-作业号-v 版本号, 例 MG1900000-张三-1-v1; 如果需要更改已提交的解答, 请在截止时间之前提交新版本的解答, 并将版本号加一;
- (5) 未按照要求提交作业, 或 **pdf 命名方式不正确**, 将会被扣除部分作业分数.

1 [30pts] Rethinking Stability of SVR

教材 5.3.2 节证明了支持向量回归具有替换样本 β -均匀稳定性, 其中 $\beta = \frac{2r^2}{\lambda m}$. 试给出更紧的界, 即 $\beta = \frac{r^2}{\lambda m}$.

Proof.

支持向量回归的优化目标函数为, 其中 $\mathbf{w} \in \mathbb{R}^d$, λ 为正则化参数。

$$F_D(\mathbf{w}) = \frac{1}{m} \sum_{i=1}^m \ell_\epsilon(\mathbf{w}, (\mathbf{x}_i, y_i)) + \lambda \|\mathbf{w}\|^2,$$

$$\ell_\epsilon(\mathbf{w}, (\mathbf{x}, y)) = \begin{cases} 0 & \text{if } |\mathbf{w}^\top \mathbf{x} - y| \leq \epsilon, \\ |\mathbf{w}^\top \mathbf{x} - y| - \epsilon & \text{if } |\mathbf{w}^\top \mathbf{x} - y| > \epsilon. \end{cases}$$

给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, 对任意 $k \in [m]$, 令 $D' = D^{k, z'_k}$ 表示训练集 D 中第 k 个样本被替换为 $z'_k = (\mathbf{x}'_k, y'_k)$ 得到的数据集。令 \mathbf{w}_D 和 $\mathbf{w}_{D'}$ 分别表示优化目标函数 $F_{D'}(\mathbf{w})$ 和 $F_D(\mathbf{w})$ 所得的最优解, 即

$$\mathbf{w}_D \in \arg \min_{\mathbf{w}} F_D(\mathbf{w}) \quad \mathbf{w}_{D'} \in \arg \min_{\mathbf{w}} F_{D'}(\mathbf{w}).$$

对任意样本 $(x, y) \in \mathcal{X} \times \mathcal{Y}$, 分下面四种情况讨论:

- 1) 若 $|\mathbf{w}_D^\top \mathbf{x} - y| \leq \epsilon$ 且 $|\mathbf{w}_{D'}^\top \mathbf{x} - y| \leq \epsilon$, 则有 $|\ell_\epsilon(\mathbf{w}_D, (\mathbf{x}, y)) - \ell_\epsilon(\mathbf{w}_{D'}, (\mathbf{x}, y))| = 0 \leq r \|\mathbf{w}_{D'} - \mathbf{w}_D\|$;
- 2) 若 $|\mathbf{w}_D^\top \mathbf{x} - y| > \epsilon$ 且 $|\mathbf{w}_{D'}^\top \mathbf{x} - y| > \epsilon$, 则有 $|\ell_\epsilon(\mathbf{w}_D, (\mathbf{x}, y)) - \ell_\epsilon(\mathbf{w}_{D'}, (\mathbf{x}, y))| = ||\mathbf{w}_D^\top \mathbf{x} - y| - |\mathbf{w}_{D'}^\top \mathbf{x} - y|| \leq |(\mathbf{w}_{D'} - \mathbf{w}_D)^\top \mathbf{x}| \leq r \|\mathbf{w}_{D'} - \mathbf{w}_D\|$;
- 3) 若 $|\mathbf{w}_D^\top \mathbf{x} - y| > \epsilon$ 且 $|\mathbf{w}_{D'}^\top \mathbf{x} - y| \leq \epsilon$, 则有 $|\ell_\epsilon(\mathbf{w}_D, (\mathbf{x}, y)) - \ell_\epsilon(\mathbf{w}_{D'}, (\mathbf{x}, y))| = ||\mathbf{w}_D^\top \mathbf{x} - y| - \epsilon| \leq ||\mathbf{w}_D^\top \mathbf{x} - y| - |\mathbf{w}_{D'}^\top \mathbf{x} - y|| \leq |(\mathbf{w}_{D'} - \mathbf{w}_D)^\top \mathbf{x}| \leq r \|\mathbf{w}_{D'} - \mathbf{w}_D\|$;
- 4) 若 $|\mathbf{w}_D^\top \mathbf{x} - y| \leq \epsilon$ 且 $|\mathbf{w}_{D'}^\top \mathbf{x} - y| > \epsilon$, 同理可得 $|\ell_\epsilon(\mathbf{w}_D, (\mathbf{x}, y)) - \ell_\epsilon(\mathbf{w}_{D'}, (\mathbf{x}, y))| \leq r \|\mathbf{w}_{D'} - \mathbf{w}_D\|$

综合上述四种情况, 对任意样本有 $|\ell_\epsilon(\mathbf{w}_D, (\mathbf{x}, y)) - \ell_\epsilon(\mathbf{w}_{D'}, (\mathbf{x}, y))| \leq r \|\mathbf{w}_{D'} - \mathbf{w}_D\|$, 由于任意凸函数加入正则项 $\lambda \|\mathbf{w}\|^2$ 变成 2λ -强凸函数, 可知函数 $F_D(\mathbf{w})$ 和 $F_{D'}(\mathbf{w})$ 是 2λ -强凸函数, 进一步有

$$\begin{aligned} F_D(\mathbf{w}_{D'}) &\geq F_D(\mathbf{w}_D) + \lambda \|\mathbf{w}_D - \mathbf{w}_{D'}\|^2, \\ F_{D'}(\mathbf{w}_D) &\geq F_{D'}(\mathbf{w}_{D'}) + \lambda \|\mathbf{w}_D - \mathbf{w}_{D'}\|^2. \end{aligned}$$

将两式相加可得

$$\begin{aligned} \|\mathbf{w}_D - \mathbf{w}_{D'}\|^2 &\leq (F_D(\mathbf{w}_{D'}) - F_D(\mathbf{w}_D) - F_{D'}(\mathbf{w}_{D'}) + F_{D'}(\mathbf{w}_D)) / 2\lambda \\ &= \frac{1}{2\lambda m} (\ell_\epsilon(\mathbf{w}_{D'}, (\mathbf{x}_k, y_k)) - \ell_\epsilon(\mathbf{w}_D, (\mathbf{x}_k, y_k)) \\ &\quad + \ell_\epsilon(\mathbf{w}_D, (\mathbf{x}'_k, y'_k)) - \ell_\epsilon(\mathbf{w}_{D'}, (\mathbf{x}'_k, y'_k))) \\ &\leq \frac{r}{\lambda m} \|\mathbf{w}_D - \mathbf{w}_{D'}\|. \end{aligned}$$

进而

$$\|\mathbf{w}_D - \mathbf{w}_{D'}\| \leq r/(\lambda m)$$

$$|\ell_\epsilon(\mathbf{w}_D, (\mathbf{x}, y)) - \ell_\epsilon(\mathbf{w}_{D'}, (\mathbf{x}, y))| \leq r^2/(\lambda m)$$

由此可知支持向量回归具有替换样本 β -均匀稳定性, 其中 $\beta = r^2/(\lambda m)$ 。 \square

2 [30pts] Generalization and Stability

对任意 $k \in [m]$, 数据集 D 和样本 $\mathbf{z} \in \mathcal{X} \times \mathcal{Y}$, 若算法 \mathfrak{L} 满足

$$\begin{aligned} \left| \hat{R}(\mathfrak{L}_D) - \sum_{\mathbf{z}' \in D^{k, \mathbf{z}}} \frac{\ell(\mathfrak{L}_{D^{k, \mathbf{z}}}, \mathbf{z}')}{m} \right| &\leq \beta_1, \\ |R(\mathfrak{L}_D) - \mathbb{E}_{\mathbf{z}' \sim \mathcal{D}}[\ell(\mathfrak{L}_{D^{k, \mathbf{z}}}, \mathbf{z}')] &\leq \beta_2. \end{aligned}$$

试证明: 对任意 $\epsilon > 0$ 有

$$P_{D \sim \mathcal{D}^m} \left(|R(\mathfrak{L}_D) - \hat{R}(\mathfrak{L}_D)| \geq \epsilon + \beta_2 \right) \leq 2 \exp \left(\frac{-2\epsilon^2}{m(\beta_1 + 2\beta_2)^2} \right).$$

Proof.

易知 $\hat{R}(\mathfrak{L}_D) = \frac{1}{m} \sum_{i=1}^m \ell(\mathfrak{L}_D, z_i)$, $R(\mathfrak{L}_D) = \mathbb{E}_{z \sim \mathcal{D}}[\ell(\mathfrak{L}_D, z)]$,

则 $\hat{R}(\mathfrak{L}_{D^{k, \mathbf{z}}}) = \sum_{\mathbf{z}' \in D^{k, \mathbf{z}}} \frac{\ell(\mathfrak{L}_{D^{k, \mathbf{z}}}, \mathbf{z}')}{m}$, $R(\mathfrak{L}_{D^{k, \mathbf{z}}}) = \mathbb{E}_{\mathbf{z}' \sim \mathcal{D}}[\ell(\mathfrak{L}_{D^{k, \mathbf{z}}}, \mathbf{z}')]$,

题设即为

$$\begin{aligned} \left| \hat{R}(\mathfrak{L}_D) - \hat{R}(\mathfrak{L}_{D^{k, \mathbf{z}}}) \right| &\leq \beta_1, \\ |\mathbb{E}_{z \sim \mathcal{D}}[\ell(\mathfrak{L}_D, z)] - \mathbb{E}_{\mathbf{z}' \sim \mathcal{D}}[\ell(\mathfrak{L}_{D^{k, \mathbf{z}}}, \mathbf{z}')] &\leq \beta_2. \end{aligned}$$

首先设函数

$$\Phi(D) = \Phi(z_1, z_2, \dots, z_m) = R(\mathfrak{L}_D) - \hat{R}(\mathfrak{L}_D)$$

对于任意 $k \in [m]$, 由题设可得

$$\mathbb{E}_D[\Phi(D)] = \mathbb{E}_D[R(\mathfrak{L}_D) - \hat{R}(\mathfrak{L}_D)] \leq \beta_2$$

给定样本 $\mathbf{z} \in \mathcal{X} \times \mathcal{Y}$, 有

$$|\Phi(D) - \Phi(D^{k, \mathbf{z}})| \leq |R(\mathfrak{L}_D) - R(\mathfrak{L}_{D^{k, \mathbf{z}}})| + |\hat{R}(\mathfrak{L}_{D^{k, \mathbf{z}}}) - \hat{R}(\mathfrak{L}_D)| \leq \beta_1 + 2\beta_2.$$

将 *MCDiarmid* 不等式应用于 $\Phi(D)$, 对任意 $\epsilon > 0$ 有

$$\begin{aligned} P_{D \sim \mathcal{D}^m} \left(|R(\mathfrak{L}_D) - \hat{R}(\mathfrak{L}_D)| \geq \beta_2 + \epsilon \right) &= 2P_{D \sim \mathcal{D}^m} \left(R(\mathfrak{L}_D) - \hat{R}(\mathfrak{L}_D) \geq \beta_2 + \epsilon \right) \\ &= 2P_{D \sim \mathcal{D}^m} (\Phi(D) \geq \beta_2 + \epsilon) \\ &\leq 2P_{D \sim \mathcal{D}^m} (\Phi(D) - \mathbb{E}[\Phi(D)] \geq \epsilon) \\ &\leq 2 \exp \left(\frac{-2\epsilon^2}{m(\beta_1 + 2\beta_2)^2} \right) \end{aligned}$$

\square

3 [40pts] Consistent Surrogate Loss

考虑对率函数 $\phi(t) = \log(1 + e^{-t})$, 回答并证明下述问题.

1. [10pts] 试求解最优实值输出函数 $f_\phi^*(\mathbf{x})$.
2. [15pts] 试求解最优实值输出函数对应的最优替代泛化风险 R_ϕ^* .
3. [15pts] 证明对率函数针对原 0/1 目标函数具有替代一致性.

Proof.

1) 对于样本 $(\mathbf{x}, y) \sim \mathcal{D}$, 基于样本空间和标记空间的联合分布, 可得到条件概率

$$\eta(\mathbf{x}) = P(y = +1|\mathbf{x})$$

给定替代函数 ϕ , 它在数据分布上 \mathcal{D} 上的替代泛化风险为

$$\begin{aligned} R_\phi(f) &= \mathbb{E}_{(\mathbf{x}, y) \sim \mathcal{D}}[\phi(yf(\mathbf{x}))] \\ &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}, \mathbf{x}}[\eta(\mathbf{x})\phi(f(\mathbf{x})) + (1 - \eta(\mathbf{x}))\phi(-f(\mathbf{x}))]. \end{aligned}$$

进一步得到最优替代泛化风险

$$R_\phi^* = \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_X} \left[\min_{f(\mathbf{x}) \in \mathbb{R}} (\eta(\mathbf{x})\phi(f(\mathbf{x})) + (1 - \eta(\mathbf{x}))\phi(-f(\mathbf{x}))) \right]$$

从而得到替代函数的最优实值输出函数为

$$\begin{aligned} f_\phi^*(\mathbf{x}) &= \arg \min_{f(\mathbf{x}) \in \mathbb{R}} (\eta(\mathbf{x})\phi(f(\mathbf{x})) + (1 - \eta(\mathbf{x}))\phi(-f(\mathbf{x}))) \\ &= \arg \min_{f(\mathbf{x}) \in \mathbb{R}} (\eta(\mathbf{x}) \log(1 + e^{-f(\mathbf{x})}) + (1 - \eta(\mathbf{x})) \log(1 + e^{f(\mathbf{x})})) \end{aligned}$$

令 $h(t) = \eta(\mathbf{x}) \log(1 + e^{-t}) + (1 - \eta(\mathbf{x})) \log(1 + e^t)$, 则 $h'(t) = 1/(1 + e^{-t}) - \eta(\mathbf{x})$;

令 $h'(t) = 0$, 得 $t = \log \frac{\eta(\mathbf{x})}{1 - \eta(\mathbf{x})}$;

又因为 $h''(t) = e^{-t}/(1 + e^{-t})^2 \geq 0$, 所以在 $t = \log \frac{\eta(\mathbf{x})}{1 - \eta(\mathbf{x})}$ 处取得最小值, 可得

$$f_\phi^*(\mathbf{x}) = \arg \min_{f(\mathbf{x}) \in \mathbb{R}} h(f(\mathbf{x})) = \log \frac{\eta(\mathbf{x})}{1 - \eta(\mathbf{x})}$$

2) 最优替代泛化风险为

$$\begin{aligned} R_\phi^* &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_X} \left[\min_{f(\mathbf{x}) \in \mathbb{R}} (\eta(\mathbf{x})\phi(f(\mathbf{x})) + (1 - \eta(\mathbf{x}))\phi(-f(\mathbf{x}))) \right] \\ &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_X} \left[\eta(\mathbf{x})\phi\left(\log \frac{\eta(\mathbf{x})}{1 - \eta(\mathbf{x})}\right) + (1 - \eta(\mathbf{x}))\phi\left(-\log \frac{\eta(\mathbf{x})}{1 - \eta(\mathbf{x})}\right) \right] \\ &= \mathbb{E}_{\mathbf{x} \sim \mathcal{D}_X} [|\eta(\mathbf{x}) \log \eta(\mathbf{x}) - (1 - \eta(\mathbf{x})) \log(1 - \eta(\mathbf{x}))|] \end{aligned}$$

3) **定理 6.1** 对替代函数 ϕ , 若最优实值输出函数满足 $f_\phi^* \in \mathcal{F}^*$, 且存在 $c > 0$ 和 $s \geq 1$ 使

$$|\eta(\mathbf{x}) - 1/2|^s \leq c^s (\phi(0) - \eta(\mathbf{x})\phi(f_\phi^*(\mathbf{x})) - (1 - \eta(\mathbf{x}))\phi(-f_\phi^*(\mathbf{x})))$$

则替代函数 ϕ 具有一致性。

下面开始证明，易知 $\phi(0) - \eta(\mathbf{x})\phi(f_\phi^*(\mathbf{x})) - (1 - \eta(\mathbf{x}))\phi(-f_\phi^*(\mathbf{x})) = \log 2 + \eta(\mathbf{x}) \log \eta(\mathbf{x}) + (1 - \eta(\mathbf{x})) \log(1 - \eta(\mathbf{x}))$,

不妨设

$$\begin{aligned} h(\eta(\mathbf{x})) &= 1^2 \cdot (\phi(0) - \eta(\mathbf{x})\phi(f_\phi^*(\mathbf{x})) - (1 - \eta(\mathbf{x}))\phi(-f_\phi^*(\mathbf{x}))) - |\eta(\mathbf{x}) - 1/2|^2 \\ &= \log 2 + \eta(\mathbf{x}) \log \eta(\mathbf{x}) + (1 - \eta(\mathbf{x})) \log(1 - \eta(\mathbf{x})) - (\eta(\mathbf{x}) - 1/2)^2 \end{aligned}$$

则 $h'(\eta(\mathbf{x})) = \log \eta(\mathbf{x}) - \log(1 - \eta(\mathbf{x})) - 2\eta(\mathbf{x}) + 1$,

则 $h''(\eta(\mathbf{x})) = \eta(\mathbf{x})/(1 - \eta(\mathbf{x})) + (1 - \eta(\mathbf{x}))/\eta(\mathbf{x}) > 0$ 恒成立,

又因为 $h'(1/2) = 0$, 所以 $h(\eta(\mathbf{x})) \geq h(1/2) = 0$,

设 $c = 1$, $s = 2$, 基于定理 6.1 可知对率函数针对原 0/1 函数具有替代一致性。

□